

P1654 OSU!: 用条件期望理解期望 DP

题目描述

有 n 次相互独立的操作。第 i 次操作以概率 p_i 成功，记为 1；以概率 $1 - p_i$ 失败，记为 0。最终会得到一个长度为 n 的 01 串。

计分规则如下：对每一段极长连续的 1，如果长度为 x ，则这一段贡献 x^3 分。

要求计算总分的期望，结果四舍五入保留 1 位小数。

输入格式

第一行一个正整数 n 。接下来 n 行，每行一个 $[0, 1]$ 之间的实数 p_i ，表示第 i 次操作成功的概率。

输出格式

输出一个实数，表示期望总分，保留 1 位小数。

输入输出样例

输入

```
3
0.5
0.5
0.5
```

输出

```
6.0
```

样例解释

长度为 3 的所有 01 串共有 8 个：

000, 001, 010, 011, 100, 101, 110, 111

对应得分分别为：

0, 1, 1, 8, 1, 2, 8, 27

总和为 48。因为每个串出现概率都是 $1/8$ ，所以期望为 $48/8 = 6.0$ 。

数据范围： $n \leq 10^5$ 。

一、题目与概率空间

这道题表面上是在求一个 01 串得分的期望，本质上是在问：每一次新操作发生以后，总分的期望会增加多少。

为了把“随机的 01 串”说清楚，我们先把所有可能结果放进同一个概率空间里。

长度为 n 的所有 01 串构成样本空间：

$$\Omega = \{0, 1\}^n$$

一个样本点记为：

$$\omega = (\omega_1, \omega_2, \dots, \omega_n)$$

其中 $\omega_i = 1$ 表示第 i 次操作成功； $\omega_i = 0$ 表示第 i 次操作失败。

因为 Ω 是有限集合，所以可以直接取全体子集作为 σ -代数：

$$\mathcal{F} = 2^\Omega$$

定义概率测度：

$$\mathbb{P}(\{\omega\}) = \prod_{i=1}^n p_i^{\omega_i} (1 - p_i)^{1 - \omega_i}$$

这就是每个具体 01 串出现的概率。

也就是说，如果某个位置是 1，就乘上这一位成功的概率 p_i ；如果某个位置是 0，就乘上失败的概率 $1 - p_i$ 。整串出现的概率就是这些概率的乘积。

定义坐标随机变量：

$$X_i(\omega) = \omega_i$$

于是：

$$\mathbb{P}(X_i = 1) = p_i, \quad \mathbb{P}(X_i = 0) = 1 - p_i$$

并且 $X_1, X_2, \dots, X_n$ 相互独立。

二、过滤族与后缀长度

1. 引入过滤族

过滤族听起来很抽象，其实在这道题里可以先把它理解成“到某一步为止，我们已经看见了哪些结果”。

设：

$$\mathcal{F}_i = \sigma(X_1, X_2, \dots, X_i)$$

它表示由前 i 次操作结果所能区分出来的全部事件。

直观地说， $\mathcal{F}_i$ 表示：到第 i 步为止，我们已经掌握的全部信息。

例如：

$$\mathcal{F}_3 = \sigma(X_1, X_2, X_3)$$

它可以表达下面这些事件：

$$\{X_1 = 1\}, \quad \{X_2 = 0, X_3 = 1\}, \quad \{X_1 = 1, X_2 = 1, X_3 = 0\}, \quad \{X_1 + X_2 + X_3 \geq 2\}$$

这些事件只依赖前 3 次操作结果，所以都属于 $\mathcal{F}_3$ 。

但是 $\{X_5 = 1\}$ 不属于 $\mathcal{F}_3$ ，因为只知道前三次操作结果时，还无法判断第五次操作是否成功。

过滤族是一串不断变细、不断增大的信息结构：

$$\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \mathcal{F}_2 \subseteq \dots \subseteq \mathcal{F}_n$$

第 0 步时几乎什么都不知道；第 1 步时知道了 X_1 ；第 2 步时知道了 X_1, X_2 ；第 i 步时知道了 $X_1, \dots, X_i$ 。

在这道题中，引入过滤族的核心作用是说明： L_{i-1} 只由前 $i-1$ 次操作结果决定，因此它是 $\mathcal{F}_{i-1}$ -可测的，也就是“过去已经知道的量”。

而 X_i 是第 i 次操作的结果，它与过去信息 $\mathcal{F}_{i-1}$ 独立，所以：

$$\mathbb{E}[X_i \mid \mathcal{F}_{i-1}] = p_i$$

即使已经知道前 $i-1$ 次操作的全部结果，第 i 次操作成功的条件期望仍然是 p_i 。

这句话是后面递推的关键：过去的量可以看成已经定下来了，而第 i 次是否成功仍然只按自己的概率 p_i 来平均。

2. 定义连续成功后缀长度

设 L_i 表示前 i 次操作中，以第 i 位结尾的连续成功后缀长度。

例如 1 1 0 1 1 1，此时 $L_6 = 3$ 。

严格地说， L_i 满足递推关系：

$$L_i = X_i(L_{i-1} + 1), \quad L_0 = 0$$

若 $X_i = 1$ ，则 $L_i = L_{i-1} + 1$ ；若 $X_i = 0$ ，则 $L_i = 0$ 。

所以 L_i 只关心“当前末尾这一段连续的 1 有多长”，不关心前面已经断开的那些段。

3. 定义前缀总分随机变量

设 S_i 表示前 i 次操作形成的 01 串的总分。题目最后要求的答案就是 $\mathbb{E}[S_n]$ 。

接下来不直接计算 S_i 的完整分布，而是只看从 S_{i-1} 到 S_i 多出来了多少分。

若第 i 次失败 ($X_i = 0$)，分数不变： $S_i - S_{i-1} = 0$ 。

若第 i 次成功 ($X_i = 1$)，末尾连续成功段被延长，长度从 L_{i-1} 变为 $L_{i-1} + 1$ ，这一段的贡献从 L_{i-1}^3 变为 $(L_{i-1} + 1)^3$ 。

于是对每个样本点 ω ，都有如下恒等式：

$$S_i - S_{i-1} = X_i((L_{i-1} + 1)^3 - L_{i-1}^3)$$

这里前面的 X_i 是一个开关：如果第 i 次失败， $X_i = 0$ ，新增分数就是 0；如果成功， $X_i = 1$ ，才会把末尾这一段的新增贡献算进去。

展开 $(L + 1)^3 - L^3 = 3L^2 + 3L + 1$ ，所以：

$$S_i - S_{i-1} = X_i(3L_{i-1}^2 + 3L_{i-1} + 1)$$

三、条件期望推出递推

1. 答案递推

现在真正要做的，就是对上面的新增分数取期望。

因为 L_{i-1} 只由前 $i-1$ 次操作决定，所以 L_{i-1} 以及 $3L_{i-1}^2 + 3L_{i-1} + 1$ 都是 $\mathcal{F}_{i-1}$ -可测的。

又因为 X_i 与 $\mathcal{F}_{i-1}$ 独立，所以 $\mathbb{E}[X_i | \mathcal{F}_{i-1}] = p_i$ 。

直观地说， $3L_{i-1}^2 + 3L_{i-1} + 1$ 是“过去已经决定的系数”，而 X_i 是“当前这一步还没发生的随机开关”。条件期望做的事，就是先固定过去，再把这个随机开关平均掉。




Figure 1: image

于是:

$$\begin{aligned}
 \mathbb{E}[S_i - S_{i-1}] &= \mathbb{E}[X_i(3L_{i-1}^2 + 3L_{i-1} + 1)] \\
 &= \mathbb{E}[\mathbb{E}[X_i(3L_{i-1}^2 + 3L_{i-1} + 1) \mid \mathcal{F}_{i-1}]] \\
 &= \mathbb{E}[(3L_{i-1}^2 + 3L_{i-1} + 1)\mathbb{E}[X_i \mid \mathcal{F}_{i-1}]] \\
 &= \mathbb{E}[(3L_{i-1}^2 + 3L_{i-1} + 1)p_i] \\
 &= p_i \mathbb{E}[3L_{i-1}^2 + 3L_{i-1} + 1] \\
 &= p_i (3\mathbb{E}[L_{i-1}^2] + 3\mathbb{E}[L_{i-1}] + 1)
 \end{aligned}$$

设 $a_i = \mathbb{E}[L_i]$, $b_i = \mathbb{E}[L_i^2]$, $\text{ans}_i = \mathbb{E}[S_i]$, 则:

$$\text{ans}_i = \text{ans}_{i-1} + p_i(3b_{i-1} + 3a_{i-1} + 1)$$

所以答案递推只需要知道两件事: 上一轮末尾连续成功长度的一阶矩 a_{i-1} , 以及二阶矩 b_{i-1} 。

2. 推出 a_i 和 b_i 的递推

既然答案需要 a_i 和 b_i , 我们还要顺手维护它们。

由 $L_i = X_i(L_{i-1} + 1)$:

$$\begin{aligned}
 a_i &= \mathbb{E}[L_i] \\
 &= \mathbb{E}[X_i(L_{i-1} + 1)] \\
 &= p_i(a_{i-1} + 1)
 \end{aligned}$$

这一步同样使用了 X_i 与 $\mathcal{F}_{i-1}$ 独立, 以及 $L_{i-1} + 1$ 是 $\mathcal{F}_{i-1}$ -可测的。

用普通 DP 的语言说，就是：如果第 i 次成功，后缀长度在原来基础上加一；如果失败，后缀长度归零。再乘上成功概率 p_i ，就得到期望后缀长度。

对于二次矩， $L_i^2 = X_i^2(L_{i-1} + 1)^2$ 。由于 $X_i \in \{0, 1\}$ ，有 $X_i^2 = X_i$ ，于是：

二阶矩也是同样的思路，只不过把后缀长度平方以后再取期望。

$$\begin{aligned} b_i &= \mathbb{E}[L_i^2] = \mathbb{E}[X_i(L_{i-1} + 1)^2] \\ &= p_i \mathbb{E}[L_{i-1}^2 + 2L_{i-1} + 1] \\ &= p_i(b_{i-1} + 2a_{i-1} + 1) \end{aligned}$$


3. 最终递推式

初始值 $a_0 = b_0 = \text{ans}_0 = 0$ 。对于 $i = 1, 2, \dots, n$ ：

$$\begin{aligned} \text{ans}_i &= \text{ans}_{i-1} + p_i(3b_{i-1} + 3a_{i-1} + 1) \\ a_i &= p_i(a_{i-1} + 1) \\ b_i &= p_i(b_{i-1} + 2a_{i-1} + 1) \end{aligned}$$

ans_n 就是答案。

这就是整道题的算法核心：从左到右扫一遍，每读入一个 p_i ，更新当前答案、一阶矩和二阶矩。



四、为什么不需要维护三次矩

不需要维护三次矩，核心原因在于：

每一步真正加入答案的，不是新的整段贡献 $(L_{i-1} + 1)^3$ ，而是旧贡献被替换以后多出来的部分：

$$(L_{i-1} + 1)^3 - L_{i-1}^3$$

这个差值展开以后，只会含有二次项、一次项和常数项。

这点很容易看错。题目里的得分确实是三次方，但我们每一步加到答案里的不是“整段三次方”，而是“这一位成功以后，末尾这段比原来多了多少”。

设第 $i - 1$ 位结尾的连续成功长度是 L_{i-1} 。

如果第 i 次成功，那么末尾这一段长度从 L_{i-1} 变成 $L_{i-1} + 1$ 。

原来这一段对总分的贡献是：

$$L_{i-1}^3$$

现在这一段对总分的贡献是：

$$(L_{i-1} + 1)^3$$

所以真正新增的分数是：

$$(L_{i-1} + 1)^3 - L_{i-1}^3$$

展开：

$$(L + 1)^3 - L^3 = L^3 + 3L^2 + 3L + 1 - L^3 = 3L^2 + 3L + 1$$

三次项 L^3 被抵消了。

因此答案增量只需要 $\mathbb{E}[L_{i-1}^2]$ 和 $\mathbb{E}[L_{i-1}]$ ，不需要 $\mathbb{E}[L_{i-1}^3]$ 。

比如当前末尾连续成功长度是 2：

原来贡献是： $2^3 = 8$

如果下一位成功，长度变成 3，新贡献是 $3^3 = 27$ 。

但是新增分数不是 27，而是 $27 - 8 = 19$ 。

而：

$$3 \cdot 2^2 + 3 \cdot 2 + 1 = 12 + 6 + 1 = 19$$

这就是为什么只需要维护一阶矩和二阶矩。

如果额外维护三次矩 $c_i = \mathbb{E}[L_i^3]$ 。

它确实也有递推：

$$c_i = p_i(c_{i-1} + 3b_{i-1} + 3a_{i-1} + 1)$$

但是 c_i 表示的是：

第 i 位结尾的连续成功后缀长度的三次方期望。

它不是前 i 位的总分期望。

总分期望是 $\text{ans}_i = \mathbb{E}[S_i]$ ，而不是 $\mathbb{E}[L_i^3]$ 。

所以如果把 c_i 看成答案，就只统计了「当前末尾这一段」，而没有统计所有已经结束或正在延长的连续段。

换句话说， c_i 不是错的量，只是不是题目要的量。题目要的是所有连续段的总分期望，而 c_i 只盯着当前后缀这一段。

五、C++ 实现代码

代码里用 `E1` 表示 a_i ，用 `E2` 表示 b_i ，用 `ans` 表示 ans_i 。数组写法更贴近上面的递推式，实际也可以改成滚动变量。

```
#include <bits/stdc++.h>
using namespace std;

const int MAXN = 1e5 + 10;

double E1[MAXN];
double E2[MAXN];
double ans[MAXN];

signed main() {
    ios::sync_with_stdio(false);
    cin.tie(nullptr);

    int n;
    cin >> n;

    E1[0] = E2[0] = ans[0] = 0.0;

    for (int i = 1; i <= n; i++) {
        double p;
        cin >> p;

        ans[i] = ans[i - 1] + p * (3 * E2[i - 1] + 3 * E1[i - 1] + 1);
```

```

        E1[i] = p * (E1[i - 1] + 1);

        E2[i] = p * (E2[i - 1] + 2 * E1[i - 1] + 1);
    }
    cout << fixed << setprecision(1) << ans[n] << "\n";

    return 0;
}

```

时间复杂度为 $O(n)$ ，空间复杂度为 $O(n)$ 。由于递推只依赖上一项，也可以用滚动变量把空间优化到 $O(1)$ 。

附录一、随机变量生成的 σ -代数

下面的附录用于补足前面用到的概率论语言。第一次阅读时，可以先抓住直观含义： σ -代数描述“能分辨哪些事件”，条件期望描述“在当前信息下做平均”。

符号	含义
Ω	样本空间
ω	样本点
$\mathcal{F}$	σ -代数
$\mathbb{P}$	概率测度
$\mathcal{G} \subseteq \mathcal{F}$	子 σ -代数，表示当前掌握的信息
$X: \Omega \rightarrow \mathbb{R}$	随机变量

由 X 生成的 σ -代数记作 $\sigma(X)$:

$$\sigma(X) = \{X^{-1}(B) : B \in \mathcal{B}(\mathbb{R})\}$$

其中 $\mathcal{B}(\mathbb{R})$ 是实数轴上的 Borel σ -代数，而

$$X^{-1}(B) = \{\omega \in \Omega : X(\omega) \in B\}$$

表示事件「 X 的取值落在 B 中」。

更完整地:

$$\sigma(X) = \{\{\omega \in \Omega : X(\omega) \in B\} : B \in \mathcal{B}(\mathbb{R})\}$$

直观理解: $\sigma(X)$ 就是只观察 X 的值时，能够判断出来的所有事件。

例如 $\Omega = \{HH, HT, TH, TT\}$ ，设 X 表示第一次抛掷结果（ H 记为 1， T 记为 0）。只观察 X 时，只能区分 $\{HH, HT\}$ 与 $\{TH, TT\}$ ，因此:

$$\sigma(X) = \{\emptyset, \Omega, \{HH, HT\}, \{TH, TT\}\}$$

附录二、条件期望

条件期望可以理解成：在只知道 $\mathcal{G}$ 这部分信息时，对随机变量 X 做出的最好平均估计。

设 $(\Omega, \mathcal{F}, \mathbb{P})$ 是概率空间， $\mathcal{G} \subseteq \mathcal{F}$ 是子 σ -代数， X 是非负或可积随机变量。

$\mathbb{E}[X | \mathcal{G}]$ 是满足下面两个条件的随机变量。

1. 可测性

$\mathbb{E}[X | \mathcal{G}]$ 是 $\mathcal{G}$ -可测的： $\mathbb{E}[X | \mathcal{G}](\omega)$ 只依赖 $\mathcal{G}$ 中已经包含的信息。

若 $\mathcal{G}$ 分不清 HHH 与 HHT ，则必须有：

$$\mathbb{E}[X | \mathcal{G}](HHH) = \mathbb{E}[X | \mathcal{G}](HHT)$$

2. 部分平均性质

对任意 $A \in \mathcal{G}$ ，都有：

$$\int_A \mathbb{E}[X | \mathcal{G}](\omega) d\mathbb{P}(\omega) = \int_A X(\omega) d\mathbb{P}(\omega)$$

即：

$$\boxed{\int_{\omega \in A} \mathbb{E}[X | \mathcal{G}](\omega) \mathbb{P}(d\omega) = \int_{\omega \in A} X(\omega) \mathbb{P}(d\omega), \quad \forall A \in \mathcal{G}}$$

附录三、条件期望的有限样本空间例子

抛三次硬币， $\Omega = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\}$ 。设 $\mathcal{G} = \mathcal{F}_2$ ，也就是只知道前两次结果。

$\mathcal{F}_2$ 会把样本空间分成四块： $A_{HH}, A_{HT}, A_{TH}, A_{TT}$ 。

在 $\mathcal{F}_2$ 看来 HHH 与 HHT 不可区分，所以：

$$\mathbb{E}[X | \mathcal{F}_2](HHH) = \mathbb{E}[X | \mathcal{F}_2](HHT)$$

在 $A_{HH} = \{HHH, HHT\}$ 上，由部分平均性质：

$$\sum_{\omega \in A_{HH}} \mathbb{E}[X \mid \mathcal{F}_2](\omega) \mathbb{P}(\{\omega\}) = \sum_{\omega \in A_{HH}} X(\omega) \mathbb{P}(\{\omega\})$$

设该块上的常数为 c_{HH} ，则：

$$c_{HH} = \frac{X(HHH) \mathbb{P}(\{HHH\}) + X(HHT) \mathbb{P}(\{HHT\})}{\mathbb{P}(\{HHH\}) + \mathbb{P}(\{HHT\})}$$

即：

$$\boxed{\mathbb{E}[X \mid \mathcal{F}_2](HHH) = \mathbb{E}[X \mid \mathcal{F}_2](HHT) = \frac{X(HHH) \mathbb{P}(\{HHH\}) + X(HHT) \mathbb{P}(\{HHT\})}{\mathbb{P}(\{HHH\}) + \mathbb{P}(\{HHT\})}}$$

更一般地，若 $\mathcal{G}$ 把有限样本空间分成信息块 $C_1, C_2, \dots, C_m$ ，则在 $\mathbb{P}(C_j) > 0$ 时：

$$\mathbb{E}[X \mid C_j] = \frac{\sum_{\omega \in C_j} X(\omega) \mathbb{P}(\{\omega\})}{\mathbb{P}(C_j)}$$

若 $\mathbb{P}(C_j) = 0$ ，该块上的取值不影响条件期望的几乎处处意义，因此可以任意定义。

附录四、核心理解

条件期望不要求 $\mathbb{E}[X \mid \mathcal{G}](\omega) = X(\omega)$ ，而是要求：在 $\mathcal{G}$ 能分辨的每一个信息块上，把 X 做加权平均。

$$\boxed{\mathbb{E}[X \mid \mathcal{G}] = \text{在只知道 } \mathcal{G} \text{ 信息时，对 } X \text{ 做出的分块平均估计}}$$

回到 P1654，最关键的一步是：

$$S_i - S_{i-1} = X_i(3L_{i-1}^2 + 3L_{i-1} + 1)$$

其中 L_{i-1} 是 $\mathcal{F}_{i-1}$ -可测的过去信息， X_i 是与过去独立的新随机结果。因此：

$$\mathbb{E}[X_i(3L_{i-1}^2 + 3L_{i-1} + 1) \mid \mathcal{F}_{i-1}] = (3L_{i-1}^2 + 3L_{i-1} + 1) p_i$$

从算法角度看，它变成了三个简单递推；从概率论角度看，它是用过滤族描述「过去信息」，用条件期望处理「当前独立随机变量」，最后得到期望 DP。

附录五、塔式定理

塔式定理说的是：如果已经按更细的信息平均过一次，再按更粗的信息平均一次，结果等于一开始就按更粗的信息平均。

基本形式

先证明塔式定理的一个常用推论：

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}]] = \mathbb{E}[X]$$

设：

$$Z = \mathbb{E}[X \mid \mathcal{G}]$$

由条件期望的定义， Z 满足两个条件：

第一， Z 是 $\mathcal{G}$ -可测的。

第二，对任意 $A \in \mathcal{G}$ ，都有：

$$\int_A Z(\omega) d\mathbb{P}(\omega) = \int_A X(\omega) d\mathbb{P}(\omega)$$

现在取：

$$A = \Omega$$

因为：

$$\Omega \in \mathcal{G}$$

所以由条件期望的定义：

$$\int_{\Omega} Z(\omega) d\mathbb{P}(\omega) = \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$$

也就是：

$$\mathbb{E}[Z] = \mathbb{E}[X]$$

又因为：

$$Z = \mathbb{E}[X \mid \mathcal{G}]$$

所以:

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}]] = \mathbb{E}[X]$$

这就是塔式定理的基本形式。

一般形式

接下来证明塔式定理的一般形式。

设:

$$\mathcal{H} \subseteq \mathcal{G}$$

其中 $\mathcal{G}$ 表示更细的信息, $\mathcal{H}$ 表示更粗的信息。

要证明:

$$\mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}] = \mathbb{E}[X | \mathcal{H}]$$

设:

$$Y = \mathbb{E}[X | \mathcal{G}]$$

再设:

$$U = \mathbb{E}[Y | \mathcal{H}] = \mathbb{E}[\mathbb{E}[X | \mathcal{G}] | \mathcal{H}]$$

我们要证明:

$$U = \mathbb{E}[X | \mathcal{H}]$$

根据条件期望的定义, 只需要证明 U 也满足 $\mathbb{E}[X | \mathcal{H}]$ 的两个条件。

1. 可测性

因为:

$$U = \mathbb{E}[Y | \mathcal{H}]$$

所以由条件期望的定义, U 是 $\mathcal{H}$ -可测的。

2. 部分平均性质

接下来证明，对任意：

$$A \in \mathcal{H}$$

都有：

$$\int_A U \, d\mathbb{P} = \int_A X \, d\mathbb{P}$$

因为：

$$U = \mathbb{E}[Y \mid \mathcal{H}]$$

所以对任意 $A \in \mathcal{H}$ ，都有：

$$\int_A U \, d\mathbb{P} = \int_A Y \, d\mathbb{P}$$

又因为：

$$Y = \mathbb{E}[X \mid \mathcal{G}]$$

并且：

$$A \in \mathcal{H}, \quad \mathcal{H} \subseteq \mathcal{G}$$

所以：

$$A \in \mathcal{G}$$

于是可以再次使用条件期望的定义：

$$\int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P}$$

两步合起来：

$$\int_A U \, d\mathbb{P} = \int_A Y \, d\mathbb{P} = \int_A X \, d\mathbb{P}, \quad \forall A \in \mathcal{H}$$

因此 U 满足 $\mathbb{E}[X \mid \mathcal{H}]$ 的定义，所以：

$$U = \mathbb{E}[X \mid \mathcal{H}]$$

也就是：

$$\boxed{\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}] = \mathbb{E}[X \mid \mathcal{H}]}$$

这就是塔式定理。

直观理解

若：

$$\mathcal{H} \subseteq \mathcal{G}$$

则 $\mathcal{G}$ 是更细的信息， $\mathcal{H}$ 是更粗的信息。

其中：

$$\mathbb{E}[X \mid \mathcal{G}]$$

表示在细信息层面上对 X 做平均。

而：

$$\mathbb{E}[\mathbb{E}[X \mid \mathcal{G}] \mid \mathcal{H}]$$

表示先在细信息块上求平均，再按照粗信息 $\mathcal{H}$ 合并平均。

塔式定理说明：

$$\boxed{\text{先按细信息平均，再按粗信息平均} = \text{直接按粗信息平均}}$$

附录六、塔式定理的例子：三次不公平抛掷

设 X_1, X_2, X_3 相互独立，且三次成功概率不同：

$$\mathbb{P}(X_1 = 1) = p_1, \quad \mathbb{P}(X_2 = 1) = 0.3, \quad \mathbb{P}(X_3 = 1) = 0.8$$

其中 1 表示 H ，0 表示 T 。

定义随机变量：

$$Y = X_1 + X_2 + X_3$$

即三次抛掷中 H 的总个数。

定义两个信息层次。

细信息:

$$\mathcal{G} = \mathcal{F}_2 = \sigma(X_1, X_2)$$

表示知道前两次结果。

粗信息:

$$\mathcal{H} = \mathcal{F}_1 = \sigma(X_1)$$

表示只知道第一次结果。

显然:

$$\mathcal{H} \subseteq \mathcal{G}$$

第一步: 按 $\mathcal{F}_2$ 平均

如果已经知道前两次结果, 那么唯一不确定的就是第三次。

因为:

$$\mathbb{P}(X_3 = 1) = 0.8, \quad \mathbb{P}(X_3 = 0) = 0.2$$

所以不能简单除以 2, 而要按照 0.8 和 0.2 加权。

例如, 前两次为 HH , 也就是:

$$X_1 = 1, \quad X_2 = 1$$

此时:

$$Y = 2 + X_3$$

所以:

$$\mathbb{E}[Y \mid X_1 = 1, X_2 = 1] = 2 + 0.8 = 2.8$$

也可以展开为:

$$3 \cdot 0.8 + 2 \cdot 0.2 = 2.4 + 0.4 = 2.8$$

注意这里不是:

$$\frac{3+2}{2} = 2.5$$

因为第三次出现 H 和 T 的概率并不相同。

四个细信息块上的条件期望如下:

前两次结果	$\mathbb{E}[Y \mid \mathcal{F}_2]$
HH	$2 + 0.8 = 2.8$
HT	$1 + 0.8 = 1.8$
TH	$1 + 0.8 = 1.8$
TT	$0 + 0.8 = 0.8$

也就是说:

$$\mathbb{E}[Y \mid \mathcal{F}_2]$$

在四个细信息块上的取值分别为:

$$2.8, \quad 1.8, \quad 1.8, \quad 0.8$$

第二步: 再按 $\mathcal{F}_1$ 平均

现在只知道第一次结果。

第一次为 H

若:

$$X_1 = 1$$

则第二次仍不确定, 并且:

$$\mathbb{P}(X_2 = 1) = 0.3, \quad \mathbb{P}(X_2 = 0) = 0.7$$

所以粗平均不是:

$$\frac{2.8 + 1.8}{2}$$

而是:

$$0.3 \cdot 2.8 + 0.7 \cdot 1.8 = 0.84 + 1.26 = 2.1$$

因此，在 $X_1 = 1$ 时：

$$\mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_2] \mid \mathcal{F}_1] = 2.1$$

第一次为 T

若：

$$X_1 = 0$$

则第二次仍然满足：

$$\mathbb{P}(X_2 = 1) = 0.3, \quad \mathbb{P}(X_2 = 0) = 0.7$$

所以：

$$\mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_2] \mid X_1 = 0] = 0.3 \cdot 1.8 + 0.7 \cdot 0.8$$

计算得到：

$$0.3 \cdot 1.8 + 0.7 \cdot 0.8 = 0.54 + 0.56 = 1.1$$

因此：

$$\mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_2] \mid \mathcal{F}_1] = \begin{cases} 2.1, & X_1 = 1, \\ 1.1, & X_1 = 0. \end{cases}$$

第三步：直接按 $\mathcal{F}_1$ 平均

现在直接计算：

$$\mathbb{E}[Y \mid \mathcal{F}_1]$$

若 $X_1 = 1$ ，则：

$$Y = 1 + X_2 + X_3$$

所以：

$$\mathbb{E}[Y \mid X_1 = 1] = 1 + \mathbb{E}[X_2] + \mathbb{E}[X_3] = 1 + 0.3 + 0.8 = 2.1$$

若 $X_1 = 0$, 则:

$$Y = X_2 + X_3$$

所以:

$$\mathbb{E}[Y \mid X_1 = 0] = 0 + 0.3 + 0.8 = 1.1$$

因此:

$$\mathbb{E}[Y \mid \mathcal{F}_1] = \begin{cases} 2.1, & X_1 = 1, \\ 1.1, & X_1 = 0. \end{cases}$$

结论

我们得到:

$$\mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_2] \mid \mathcal{F}_1] = \mathbb{E}[Y \mid \mathcal{F}_1]$$

这正是塔式定理:

$$\boxed{\mathbb{E}[\mathbb{E}[Y \mid \mathcal{F}_2] \mid \mathcal{F}_1] = \mathbb{E}[Y \mid \mathcal{F}_1]}$$

它说明: 先按更细的信息做条件期望, 再按粗信息做条件期望, 等于直接按粗信息做条件期望。

附录七、可测性

可测性在本文里主要承担一个直观角色: 判断一个量是不是“只靠当前信息就能确定”。

设:

$$X : \Omega \rightarrow \mathbb{R}$$

是随机变量, $\mathcal{G} \subseteq \mathcal{F}$ 是一个子 σ -代数。

如果对任意 Borel 集合:

$$B \in \mathcal{B}(\mathbb{R})$$

都有：

$$\{\omega \in \Omega : X(\omega) \in B\} \in \mathcal{G}$$

那么就说：

$$X \text{ 是 } \mathcal{G}\text{-可测的}$$

其中：

$$\{\omega \in \Omega : X(\omega) \in B\}$$

是事件“ X 的取值落在 B 中”。

直观地说：

X 是 $\mathcal{G}$ -可测的，表示只根据 $\mathcal{G}$ 中的信息，就可以确定 X 的取值。

有限样本空间中的理解

假设：

$$\Omega = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\}$$

表示抛掷三次硬币。

设：

$$\mathcal{G} = \mathcal{F}_2 = \sigma(X_1, X_2)$$

表示只知道前两次抛掷结果。

那么 $\mathcal{G}$ 会将样本空间分成四个信息块：

$$A_{HH} = \{HHH, HHT\}$$

$$A_{HT} = \{HTH, HTT\}$$

$$A_{TH} = \{THH, THT\}$$

$$A_{TT} = \{TTH, TTT\}$$

定义:

$$Y(\omega) = \text{前两次中}H\text{的个数}$$

那么:

$$Y(HHH) = Y(HHT) = 2$$

$$Y(HTH) = Y(HTT) = 1$$

$$Y(THH) = Y(THT) = 1$$

$$Y(TTH) = Y(TTT) = 0$$

可以看到, 在 $\mathcal{G}$ 的每一个信息块中, Y 的值都是常数。

所以:

Y 是 $\mathcal{G}$ -可测的

因为只知道前两次结果, 就能确定 Y 。

反例

如果定义:

$$Z(\omega) = \text{第三次是否为}H$$

即第三次是 H 时 $Z = 1$, 第三次是 T 时 $Z = 0$ 。

那么:

$$Z(HHH) = 1, \quad Z(HHT) = 0$$

但是 HHH 和 HHT 在 $\mathcal{G} = \mathcal{F}_2$ 看来属于同一个信息块, 因为前两次都是 HH 。

如果 Z 在同一个信息块中取不同的值, 就说明它使用了第三次的信息。

因此:

Z 不是 $\mathcal{G}$ -可测的

在有限样本空间中，可以记住这个标准：

$$X \text{ 是 } \mathcal{G}\text{-可测} \iff X \text{ 在 } \mathcal{G} \text{ 的每个信息块上都是常数}$$

附录八、提取已知量

提取已知量就是前面递推中最常用的那一步：已经由过去信息决定的量，在对过去信息求条件期望时，可以像常数一样提出去。

条件期望有一个非常重要的性质，叫作“提取已知量”。

为了避免符号混乱，本节用 Y 表示“已知量”，用 X 表示“待平均的随机量”。

如果 X 和 XY 可积，并且 Y 是 $\mathcal{G}$ -可测的，那么：

$$\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}]$$

它的意思是：

如果 Y 的值已经能够由 $\mathcal{G}$ 中的信息确定，那么在对 $\mathcal{G}$ 求条件期望时， Y 就可以像常数一样提出去。

如果 X, Y 非负，则上式也成立，不过两边可能同时取 $+\infty$ 。

有限样本空间下的证明

设 $\mathcal{G}$ 是一个子 σ -代数。

在有限空间中，可以把 $\mathcal{G}$ 理解为一种“信息分辨能力”。它会把 Ω 分成若干个互不相交的信息块：

$$C_1, C_2, \dots, C_m$$

满足：

$$\Omega = C_1 \cup C_2 \cup \dots \cup C_m$$

并且：

$$C_i \cap C_j = \emptyset, \quad i \neq j$$

这些 C_j 就是 $\mathcal{G}$ 能分辨出的最小信息块。

例如，抛掷三次硬币，只知道前两次结果时：

$$\mathcal{G} = \mathcal{F}_2$$

此时信息块为:

$$C_1 = \{HHH, HHT\}$$

$$C_2 = \{HTH, HTT\}$$

$$C_3 = \{THH, THT\}$$

$$C_4 = \{TTH, TTT\}$$

我们证明:

$$\boxed{\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}]}$$

只需要在每个信息块 C_j 上证明它成立。

因为 Y 是 $\mathcal{G}$ -可测的, 所以 Y 在每个信息块 C_j 上都是常数。

设:

$$Y(\omega) = y_j, \quad \forall \omega \in C_j$$

也就是说, 在信息块 C_j 上, Y 是常数 y_j 。

以下默认 $\mathbb{P}(C_j) > 0$ 。若 $\mathbb{P}(C_j) = 0$, 该块上的取值不影响条件期望的几乎处处意义。

1. 计算左边

在块 C_j 上:

$$\mathbb{E}[XY \mid \mathcal{G}](\omega) = \mathbb{E}[XY \mid C_j], \quad \omega \in C_j$$

展开为加权平均:

$$\mathbb{E}[XY \mid C_j] = \frac{\sum_{\omega' \in C_j} X(\omega')Y(\omega')\mathbb{P}(\{\omega'\})}{\mathbb{P}(C_j)}$$

因为在 C_j 上:

$$Y(\omega') = y_j$$

所以:

$$X(\omega')Y(\omega') = X(\omega')y_j$$

代入得:

$$\mathbb{E}[XY \mid C_j] = \frac{\sum_{\omega' \in C_j} X(\omega')y_j \mathbb{P}(\{\omega'\})}{\mathbb{P}(C_j)}$$

由于 y_j 对这个信息块里的所有 ω' 都相同, 所以可以提出求和号:

$$\mathbb{E}[XY \mid C_j] = y_j \frac{\sum_{\omega' \in C_j} X(\omega') \mathbb{P}(\{\omega'\})}{\mathbb{P}(C_j)}$$

而后面的这一项正是:

$$\mathbb{E}[X \mid C_j]$$

所以:

$$\mathbb{E}[XY \mid C_j] = y_j \mathbb{E}[X \mid C_j]$$

2. 计算右边

当:

$$\omega \in C_j$$

时, 有:

$$Y(\omega) = y_j$$

并且根据有限样本空间中条件期望的分块定义:

$$\mathbb{E}[X \mid \mathcal{G}](\omega) = \mathbb{E}[X \mid C_j]$$

所以:

$$Y(\omega) \mathbb{E}[X \mid \mathcal{G}](\omega) = y_j \mathbb{E}[X \mid C_j]$$

这与左边完全相同。

因此，在每个信息块 C_j 上，都有：

$$\mathbb{E}[XY \mid \mathcal{G}](\omega) = Y(\omega)\mathbb{E}[X \mid \mathcal{G}](\omega)$$

于是整个样本空间上成立：

$$\boxed{\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}]}$$

核心理解

在每个信息块 C_j 上，如果 Y 是 $\mathcal{G}$ -可测的，那么 Y 就是一个固定常数 y_j 。

所以：

$$XY = y_j X$$

于是：

$$\text{块内平均}(XY) = \text{块内平均}(y_j X) = y_j \text{块内平均}(X)$$

翻译成条件期望，就是：

$$\mathbb{E}[XY \mid \mathcal{G}] = Y\mathbb{E}[X \mid \mathcal{G}]$$

这就是“提取已知量”的本质。